哈爾濱工業大學

实验报告

实 验（一）

题　　目　汉语分词系统

专　　业　自然语言处理

学　　号　1161000309

班　　级　1603104

学　　生　高靖龙

指 导 教 师　杨沐昀

实 验 地 点　G208

实 验 日 期　10.9.2018-10.30.2018

计算机科学与技术学院

目 录

第 1 章 实验基本信息

1.1 实验目的

本次实验目的是对汉语自动分词技术有一个全面的了解，包括从词典的建立、分词算法的实现、性能评价和优化等环节。本次实验所要用到的知识如下：

- 基本编程能力（文件处理、数据统计等）
- 相关的查找算法及数据结构实现能力
- 语料库相关知识
- 正反向最大匹配分词算法
- N 元语言模型相关知识
- 分词性能评价常用指标

1.2 实验环境与工具

1.2.1 硬件环境

处理器：	Corei7
内存：	8G
系统类型：	64位

1.2.2 软件环境

系统：	manjaro gnome linux1.80(主)、win10(辅)
IDE：	jetbrains pycharm
文本编辑器：	noteapp、atom、vim
编程语言：	python3

第 2 章 实验内容

2.1 词典的构建

要求

输入文件：199801_seg.txt（1998 年 1 月《人民日报》的分词语料库，有版权限制!）
输出：dic.txt（自己形成的分词词典）

PFR 语料库格式

PFR 语料库标注词性的格式为“词语/词性”，语料中除了词性标记以外，还有“短语标记”，以方括号括住若干 “词语/词性”对，紧跟“/短语类别”。每行开头是时间标识以“/m”结尾，然后是空格，之后是该行句子的词性、短语标记。

隔断正则表达式

```
"^.*?/m +|/[a-zA-Z\]]+ *|\["
```

字典文件格式说明

每行一个记录，为“词 词频”，即词+空格+词频，按词频从大到小排列。

字典统计分析

字典总长度：55310
词长分布：不同长度的词在字典中出现的频率

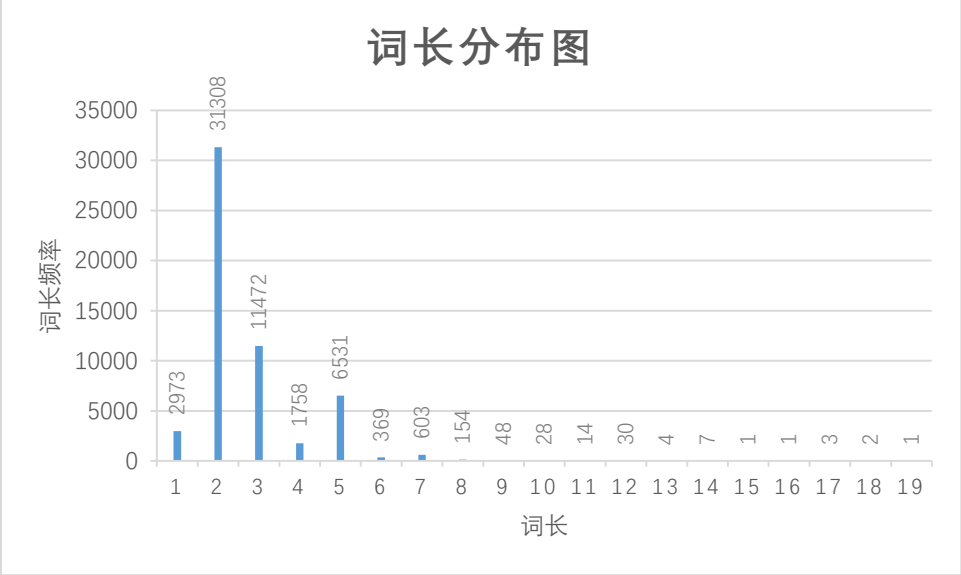

字典内标点符号统计

11 种标点符号： ， 。 、 （ ） ？ ！ ——— …… — ——

2.2 正反向最大匹配分词实现

内容

输入文件：199801_sent.txt（1998 年 1 月《人民日报》语料，未分词）
dic.txt(自己形成的分词词典)
输出：seg_FMM.txt 和 seg_BMM.txt(正反向最大匹配分词结果，格式参照分词语料)

实现心得

1. **字符串索引**
   编写实现中，对于字符串的索引str[i,j]的变化要清晰，特别是BMM，实现上较为反直觉。
2. **最大词长截断**
   使用字典最大词长截断字符串，能得到可接受的速度，如果不截断的话则无法处理长串。
3. **匹配失败**
   如果某个位置匹配失败，即没有任何字典词以它为前缀（FMM）或后缀（BMM），则要将其作为一个独立的词。
4. **F/B相似**
   FMM\BMM两者结构非常相似，区别主要集中在循环方向以及匹配成功

一个词后的匹配目标更新。

5. **BMM分词逆序**
   BMM的分词结果不能直接输出，还要进行顺序的倒置，这是因为BMM是由后向前匹配查词的。

2.3 正反向最大匹配分词性能分析

内容

输入文件：199801_seg.txt（1998 年 1 月《人民日报》的分词语料库）
seg_FMM.txt、seg_BMM.txt
输出：score.txt(包括准确率（precision）、召回率（recall）， F 值的结果文件)

实现思路

1. TP+FP=len（tarseg）,TP+FN=len（corpusseg）
   故对于precision、recall、F，我们只需要统计TP。
2. 分别从corpus、targetsegfile中读取分词序列，存储到clist，tlist中。
3. 使用两个指针i、j同步的在两列表上移动，并统计移动到当前位置的**总字数差值ct。**
   ct=clist[：i]的总字数-tlist[：i]的总字数。
4. ct为0则匹配成功，TP+1。否则说明当前分词失败，进入重定位模式。
5. 重定位模式负责重新找到下一个成功分词的开头，即下一个ct为0的地方。实现上即当ct>0时说明corpus超前，就移进j；反之移进i。

实现心得

1. 一个python容易惯性思维写错的地方：

```
#TODO 特别容易写错的地方！下面是错误实例
#if word == '' or '\n':
if word == '' or word=='\n':
    continue
```

在判断语句中，’\n’单独出现时被作为True判定。则循环永远进入，continue语句被执行，跳过其后的代码。

2. 实现细节上，对于 ct 的更新不能简单的更新为
   `ct += len(corpusseg[i]) - len(targetseg[j])`
   因为在重定位阶段，一次只移动 i、j 之一，这样就将旧的词语新词对比，不符合设计初衷。解决方案是针对 i、j 重定位中移动的情况区别处

理。

```
# 使用flag区分匹配、重定位j、重定位i这三种情况
flag=0
# 移进的字符数量差corpos-target
ct=0

while True:
    if i==lcorpus or j==ltarget:
        break

    if flag==0:
        ct += len(corpusseg[i]) - len(targetseg[j])
    elif flag==1:
        ct -= len(targetseg[j])
    else:
        ct += len(corpusseg[i])
    if ct==0:
        if flag==0:
            TP+=1
        i+=1
        j+=1
        flag = 0
    elif ct>0:
        j+=1
        flag = 1
    else:
        i+=1
        flag = 2
```

3. 实现中做了两个版本，第一个版本不是基于list的而是基于字符串的，看起来非常不直观（基于list的已经非常不直观了！）所以写了第二个版本，第一个版本作为一个对比函数使用。

FMM 与 BMM 分词精度差异分析

1. 分词精度统计结果

	TP	TP+FP	TP+FN	P	R	F
FMM$_{SEG}$	1088311	1113018	1121447	0.977802	0.970452	0.974113
BMM$_{SEG}$	1090501	1112991	1121447	0.979793	0.972405	0.976085
FMM$_{BMM}$	1083746	1113018	1112991	0.973700	0.973723	0.973712

BMM性能对于FMM有提升：分词数减少、TP增多。

2. 精度差异分析
   a) 理论差异
   FMM和BMM的差别在于查询的方向不同，即FMM倾向前缀匹配而BMM倾向于后缀匹配。

b) 理论差异对分词的影响
实验中由于训练集和测试集是相同的，所以不存在集外词，因此性能影响就主要在于分词歧义。
对于无歧义的词显然FMM、BMM没有差别，对于组合型的词FMM和BMM都不分割。但是对于交集型歧义，如ABC，FMM倾向：AB C，而BMM倾向A BC。
因此性能的差异是出现在对集中型歧义的分割上。

c) 对词分布的猜测
由于BMM精度较高，猜测样本中集中型歧义中A BC出现概率更高。

d) 分析分布
实际上BMM与FMM算法的运行过程就是对集中型歧义的探究。
通过统计即可分析出前缀集中、后缀集中、组合歧义、在seg被分割的组合歧义、在seg中没有分割的组合歧义在文本的占比。

SEG=无歧义+后缀集中+前缀集中+非切分组合歧义+切分组合型歧义=1121447
BMM_{SEG}.TP=无歧义+后缀集中+非切分组合歧义=1090501
FMM_{SEG}.TP=无歧义+前缀集中+非切分组合歧义=1088311
$SEG-BMM_{SEG}$.TP=切分组合型歧义+前缀集中 =30946
$SEG-FMM_{SEG}$.TP=切分组合型歧义+后缀集中=33136
FMM_{BMM}.TP =无歧义词+非切分组合型歧义=1083746
对上述等式进行变换：

无歧义+非切分组合	前缀集中	后缀集中	切分组合	合计
1083746	4565	6755	26381	1121447
0.966381	0.004070	0.006023	0.023524	1

e) 结论：由于在文本中集中歧义划分时，A BC 型比 AB C 型占比更多，所以后项匹配比前项匹配性能更好。

2.4 基于机械匹配的分词系统的速度优化

内容

输入文件：199801_sent.txt（1998 年 1 月《人民日报》语料，未分词）
输出：timeCost.txt（分词所用时间）

优化方案

1. 截断优化查询
   a) 字典最大词长截断
   对于一个字典，若词长最大为maxL，则我们在FMM、BMM是，查询的词长最大也应是maxL。
   b) 字典词长截断
   受最大词长截断的启发，我们存储字典中出现的词长L1，L2，，Ln，我们只对目标文本中长度在这些范围中的词进行查询。

c) 性能提升分析

词长分布的稀疏性

我们之前对于字典进行过分析，可知字典的词长为1-26，因此空间代价可以忽略不计。同时词长19、20、21、24、26没有出现，因此循环次数比最大词长截断减少20%。

可选的进一步筛选

我们看到有的词长在字典中的词频实际上非常少，我们可以直接省去这些词长，而不会带来很大的准确性损失。

但是即使不这么做，使用简单的最大词长截断，算法总运行时长仍然能控制在3min内（包括FMM、BMM、IO、准确性分析、计时函数）。

2. 散列表优化：一种时空的tradeoff

使用散列表对查询速度进行优化，是一种时空的tradeoff。

a) 算法描述

散列

散列表算法使用散列函数对内容进行散列，将散列结果作为数组索引，将内容存储到对应数组索引处。因此数组并不是完全填满的，会出现冗余的空间。

冲突

由于散列函数通常不满足单射，因此会出现多个内容的散列相同，对同一数组索引竞争，这种现象成为散列冲突。

冲突的解决

本次实现使用线性开放定址法，即冲突发生是，线性寻找下一个可用位置存储内容。负载因子取0.5-0.75之间，经测试超出该范围性能提升不显著。

b) 性能提升分析

散列表拿空间换时间，所以能提升性能，特别的是需要设计好散列函数，散列函数决定hashlist的性能。

这里参考java.String.hashCode()的实现对字符串进行散列。

c) 算法实现

```
def getHashCode(words):
    """
    散列函数。参考java.string.hashCode()实现
    :param words: 词，字符串
    :return: 散列值
    """
    s = 17
    for c in words:
        s = 31 * s + ord(c)
    return s
```

核心的散列函数，经典实现。

31作为乘数的原因：

cpu能通过位移来优化计算。31*t=t<<5-1
31散列具有统计上的优势。

2.5 基于统计语言模型的分词系统实现

内容

输入文件：test_sent.txt（1998 年人民日报局部语料，未分词，最终测试集）
dev_seg.txt（1998 年人民日报局部语料，分词，用于调试优化语言模型） 199801_seg.txt
dic.txt（自己形成的分词词典）
输出：seg_LM.txt（利用统计语言模型分词结果，格式参照分词语料）

须对程序中的重点实现代码进行说明（可用流程图对算法进行辅助说明）；对比分析各种不同分词方法的性能；

前缀词典

1. 算法原理
   前缀词典：元词典记录词和词频，将元词典中词语的所有前缀词都添加词典中，如果前缀词没有在原词典出现则其频率设为0，若有则设为原词频。
2. 算法实现
   简单的对每一个词，反向遍历，提取出前缀添加到词典中,并设置词频。

全切分有向图 DAG

1. 算法原理
   对于字符串s，考察其每个字s[k]，对于s[k:i+1]，i=0,1,2..,依次到前缀词典lfreq中查找，若查到且频率非零，则对k存储i，若没有查到则说明没有以s[k]为开头的词在lfreq查尽了。最终得到每个k的一组i，s[k:i+1]表示一个可能分词。
2. 算法实现
   DAG存储：dict{k : [k , j , ..] , m : [m , p , q] , ...},s[k:j+1]表示一个可能分词。
   按上述原理编写循环分支。
3. 实现细节
   可能存在对于某个字s[k]，在lfreq中没有其前缀词，则此时也必须给出分词，将该字本身s[k:k+1]作为一个分词存入DAG。

UnigramModel

1. 算法原理
   在DAG的基础上，动态规划寻找1-GramModel最大概率分词序列。

   a) **概率公式**
   $\mathrm{Seg} = \mathrm{argmax}\ \mathrm{P}(\mathrm{Seg}|\mathrm{sentence}, \mathrm{Dict}) =$
   $\mathrm{argmax} \prod_0^{len(Seg)-1} P(word_i|Seg, Dict)$

   b) **动态规划转移方程**
   定义问题L(j)为sentence[j:]的1-GramModel最大概率分词序列。
   $\mathrm{L(j)} = \max(\mathrm{P}(\mathrm{sentence}[\mathrm{j}:\mathrm{i}+1]) * \mathrm{P}\left(\mathrm{L}(\mathrm{i}+1)\right), \mathrm{i} \in \mathrm{DAG}[\mathrm{j}]$

   c) **重叠子问题**
   若DAG[j_1]、DAG[j_2]均包含i_0则子问题重叠。

2. 算法实现
   路径存储：route=[]，route[idx词首索引]=(子问题概率，词尾索引)

```
#初始化，该实现中所有值均 Log 化，有效防止下溢出
route[N] = (0, -1)
logtotal = log(ltotal)
for idx in range(N - 1, -1, -1):
动态规划转移方程：getFreq 对概率进行了加一平滑
    route[idx] = max((log(getFreq(lfreq,sentence[idx:x + 1]))
- logtotal + route[x + 1][0], x) for x in DAG[idx])
```

BigramModel

1. 算法原理
   在DAG的基础上，动态规划寻找2-GramModel最大概率分词序列。

   a) **概率公式**
   $\mathrm{Seg} = \mathrm{argmax}\ \mathrm{P}(\mathrm{Seg}|\mathrm{sentence}, \mathrm{Dict}) =$
   $\mathrm{argmax} \prod_0^{len(Seg)-1} P(word_i|word_{i-1}, Seg, \mathrm{Dict})$

   b) **动态规划转移方程**
   定义问题组$\{\mathrm{L}_{idx}^{i}|\mathrm{i} \in \mathrm{DAG}[\mathrm{idx}]\}$,
   $\mathrm{L}_{idx}^{i} = argmax\ P(Seg\ for\ sentence[i+1::]|word[idx:i], Dict)$

   转移方程

L_{idx}^{i}
$= argmax\ P(L_i^k)$
$* P(sentence[i:k+1] | sentence[idx:i+1]), for\ k\ in\ DAG[i]$

c) **重叠子问题**

若DAG[j_1]、DAG[j_2]均包含i_0则子问题重叠。

2. 算法实现

a) **路径存储**：routeDAG=[[]]，routeDAG[idx]=[L_{idx}^{0},L_{idx}^{1},,L_{idx}^{n}]

b) **平滑算法**：加一平滑

c) **初始化**：

```
routeDAG[N - 1] = []
routeDAG[N - 1].append((N - 1, "TAIL", 1))
```

d) 动态规划迭代：

```
value, y = max((getPYX(sentence[idx:x + 1], sentence[x + 1:y
+ 1], dict) * v, y) for y, m, v in routeDAG[x + 1])

routeDAG[idx].append((x, y, value))
```

e) **二元条件概率字典构造**：

根据文件，获取包括^$的二元概率列表

格式：

dict{条件词:{(目标词1,概率),(目标词2,概率),,,(目标词n,概率)}}

遍历seg文件，统计条件概率，对于所有频率均+1，实现平滑算法。

f) **分词结果构造**

由reouteDAG[0]开始递归查询，获取索引形式的分词形式，之后将该序列转换成词序列。

性能对比

1. 集内性能

	TP	Pall	Tall	P	R	F
FMM	1088311	1113018	1121447	0.9778	0.9704	0.9741
BMM	1090501	1112991	1121447	0.9797	0.9724	0.9760
Bigram	1088308	1113019	1121447	0.9778	0.9704	0.9741
Unigram	1103483	1113484	1121447	0.9910	0.9839	0.9874

a) 性能排序：在本次实验中，Unigram>BMM>FMM≈Bigram

b) 性能分析：为什么 Bigram 性能表现不如 Unigram？

i. Bigram 概率空间比 Unigram 大一个数量级，数据量 可能对 Unigram 还算充足但是在 Bigram 中已经稀疏了。

ii. 平滑算法选择的较为简单，导致 Bigram 不能更好的反映语言分布。使用 Good-Turing smoothing 或简单的调整加 x 平滑法中的 x 都能带来小幅度的提升。

iii. 在计算概率过程中程序可能存在问题，但是暂时没有排查到。

2. 集外性能

	TP	Pall	Tall	P	R	F
FMM	3387	3948	3734	0.857903	0.90707	0.881802
BMM	3383	3948	3734	0.85689	0.905999	0.88076
Bigram	3384	3949	3734	0.856926	0.906267	0.880906
Unigram	3436	3957	3734	0.868335	0.920193	0.893512

针对语料库，分割出训练集和测试集，在测试集上性能排名和集内性能排名差别不大。

参考文献

[1]Thomas H.Cormen．Introduction to Algorithms[M]．北京：机械工业出版社，2013：142-160
[2]Christopher D. Manning，Hinrich Schutez．统计自然语言处理基础[M]．北京：电子工业出版社，2005：1-289
[3]周志华．机器学习[M]．北京：清华大学出版社，2016：23-46
[4]宗成庆．统计自然语言处理 (2nd ed.) [M]．北京：清华大学出版社，2013：1-289
[5] Python3.7.1 Documentation. Docs.python.org. https://docs.python.org/3/, November 3, 2018.